

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor(es): Enzo Rosim (RA: 187389)

Repositório / Código Reprodutível:

<https://github.com/EnzoRosim/mlp-regression-ablation-study>

1. Configuração Experimental e Reprodutibilidade

1.1. Pré-processamento e Partição dos Dados

Os dados (300 observações) foram divididos em treino (10%, 30 exemplos), validação (10%, 30 exemplos) e teste (80%, 240 exemplos), com `random_state=42`. Os índices foram salvos em disco e reutilizados em todos os experimentos, garantindo partições idênticas. Dado o volume reduzido de treino, a tarefa é altamente suscetível ao sobreajuste.

As variáveis x e y foram padronizadas (média 0, desvio padrão 1) via `StandardScaler`, com o ajuste (*fit*) restrito ao conjunto de treino para evitar vazamento de dados (*data leakage*); validação e teste receberam apenas a transformação. As métricas finais (Seção 3) foram calculadas após reverter essa padronização.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* é uma rede MLP básica treinada estritamente com **SGD padrão** (sem aceleradores adaptativos como Adam e sem termo de *momentum*). Nenhuma regularização explícita (L1, L2, Dropout) foi aplicada nesta fase.

A busca empírica pela melhor configuração envolveu a variação sistemática de três arquiteturas (1 e 2 camadas ocultas, com 32 a 128 neurônios) combinadas com quatro taxas de aprendizado ($\eta \in \{0,01; 0,03; 0,05; 0,10\}$), totalizando 12 configurações avaliadas estritamente pelo menor erro de validação (MSE). A configuração vencedora manteve a topologia inicialmente proposta (128 $\rightarrow$ 64 neurônios), porém revelou que a taxa de aprendizado originalmente adotada ($\eta = 0,01$) era excessivamente conservadora para um otimizador sem momentum: a menor perda de validação (MSE = 0,9663, na escala padronizada) foi obtida com $\eta = 0,10$, valor dez vezes maior que o inicial. O critério de parada (*patience*) também foi ajustado empiricamente: comparando *patience*=20 e *patience*=50 (este último combinado com um piso mínimo de 150 épocas antes da parada antecipada poder ser acionada), observou-se que o valor de 20 interrompia o treinamento prematuramente, capturando modelos ainda próximos da inicialização aleatória. A Tabela 1 detalha o espaço de busca e a configuração final selecionada.

Table 1: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida (Vanilla)
Topologia das Camadas	1 camada [32]; 2 camadas [64,32] e [128,64]	Entrada $\rightarrow$ Densa(128) $\rightarrow$ Densa(64) $\rightarrow$ Saída(1)
Função de Ativação	ReLU	ReLU
Otimizador	SGD Padrão (momentum = 0,0), $\eta \in \{0,01; 0,03; 0,05; 0,10\}$	SGD ($\eta = 0,10$)
Tamanho do Lote	32 (fixo; dado o reduzido volume de treino — 30 exemplos —, lotes maiores equivaleriam a treinamento em modo <i>full-batch</i>)	32
Função de Custo	Erro Quadrático Médio (MSE)	MSELoss
Critério de Parada	<i>Early Stopping</i> : <i>patience</i> $\in \{20, 50\}$	Patience = 50 (piso mínimo de 150 épocas)
Semente Aleatória	Sementes fixas para reprodutibilidade	Seed = 42

2. Dinâmica de Treinamento e Convergência (Baseline vs. Modificados)

A evolução das curvas de perda (MSE) ao longo das épocas foi monitorada para verificar a estabilidade do SGD e comparar a dinâmica do *baseline* com os modelos contendo componentes adicionais (Figura 2).




Figure 1: Convergência da MLP Baseline ($\eta = 0,10$, sem momentum).




Figure 2: Convergência com Momentum ($\beta = 0,9$, $\eta = 0,01$).

Análise Crítica da Dinâmica de Convergência:

- **Estabilidade do SGD:** O *baseline* ($\eta = 0,10$, sem momentum) apresentou picos periódicos e crescentes de perda (Figura 1), característicos de *overshooting*: a taxa elevada, necessária para acelerar a convergência lenta observada com $\eta = 0,01$, faz as atualizações ultrapassarem repetidamente o mínimo, evidenciando um *trade-off* entre velocidade e estabilidade no SGD vanilla.
- **Sobreajuste:** A instabilidade do baseline mascarou o descolamento clássico entre treino e validação, dificultando identificar um ponto único de início de sobreajuste.

- **Aceleração com Momentum:** O momentum ($\beta = 0,9$, $\eta = 0,01$) não reduziu o número de épocas até a parada (ambos pararam em 150), mas produziu convergência visivelmente mais suave, sem os picos do baseline, e menor perda de validação final — refletida no maior R^2 no teste (Seção 3).

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar rigorosamente o efeito de cada componente, a arquitetura base ($128 \rightarrow 64$ neurônios, ReLU) foi mantida idêntica à da Tabela 1 em todas as variações a seguir:

1. **Baseline + Momentum:** SGD com momentum $\beta = 0,9$ (retorno a $\eta = 0,01$, ver Seção 2).
2. **Baseline + Regularização L2:** *weight decay* $\lambda_{L2} = 10^{-3}$.
3. **Baseline + Regularização L1:** penalização manual $\lambda_{L1} = 10^{-4}$.
4. **Baseline + Dropout:** $p = 0,2$.
5. **Modelo Combinado:** Momentum ($\beta = 0,9$) + L2 ($\lambda_{L2} = 10^{-3}$), combinando os dois componentes que isoladamente apresentaram melhor desempenho.

A avaliação final foi realizada sobre os 240 exemplos do conjunto de teste (80%), não utilizados em nenhuma etapa de treino ou ajuste de hiperparâmetros. Os resultados estão organizados na Tabela 2.

Table 2: Resultados do Estudo de Ablação no Conjunto de Teste.

Modelo / Variação	MSE	RMSE	MAE	R^2	Épocas até Convergência
Baseline Vanilla (SGD sem momentum)	0.5049	0.7106	0.5858	0.0236	150
Baseline + Momentum ($\beta = 0.9$)	0.5022	0.7087	0.5755	0.0288	150
Baseline + Regularização L2 ($\lambda = 10^{-3}$)	0.5002	0.7073	0.5816	0.0326	150
Baseline + Regularização L1 ($\lambda = 10^{-4}$)	0.4880	0.6985	0.5759	0.0563	150
Baseline + Dropout ($p = 0.2$)	0.4936	0.7026	0.5789	0.0454	207
Modelo Combinado (Melhor)	0.4823	0.6945	0.5620	0.0674	185




Figure 3: Dispersão real vs. previsto no teste — Modelo Combinado ($y = x$ ideal em vermelho).




Figure 4: Distribuição dos resíduos no conjunto de teste — Modelo Combinado.

4. Discussão e Lições Aprendidas

- **Impacto do SGD Vanilla no Regime de Poucos Dados:** O baseline teve o pior desempenho ($R^2 = 0,0236$) e foi instável (Seção 2). Entre as regularizações isoladas, o **L1** exerceu

maior contenção de variância ($R^2 = 0,0563$), superando Dropout (0,0454) e L2 (0,0326) — plausivelmente porque, com a rede superparametrizada em relação aos 30 exemplos de treino, a esparsidade induzida pelo L1 reduz efetivamente a capacidade ativa do modelo de forma mais agressiva que a simples atenuação de pesos do L2.

- **Ação dos Hiperparâmetros:** O momentum não acelerou a parada, mas eliminou o *overshooting* do baseline. O Dropout foi o mais lento a convergir (207 épocas), pelo ruído adicional da desativação aleatória de neurônios, ainda assim superando baseline e L2. Um achado relevante: a taxa de aprendizado ótima depende da presença de momentum — $\eta = 0,10$ favoreceu o SGD puro mas degradou o desempenho com momentum, mostrando que os dois hiperparâmetros não são independentes.
- **Análise de Resíduos e Limitações:** O Parity Plot (Figura 3) revela regressão à média: as previsões concentram-se numa faixa ($-0,7$ a $1,1$) mais estreita que a variável real ($-1,5$ a $2,7$), com valores extremos sistematicamente subestimados em magnitude. O Gráfico de Resíduos (Figura 4) confirma isso: a maior dispersão de erros ocorre na faixa de previsões mais frequente ($\approx 0,5$ – $0,7$), onde diversos valores reais distintos são comprimidos para previsões semelhantes. Esse padrão reflete a limitação central do experimento: apenas 30 exemplos de treino para uma função não linear ruidosa, mesmo com regularização, dificultam capturar a amplitude completa do sinal.